

# Göğüs Röntgenlerinde Otomatik Tüberküloz Sınıflandırması için Transfer Öğrenme Yaklaşımı

Ahmet Utku ELİK, 4010940078

## I. GİRİŞ

Tüberküloz (TB), Mycobacterium tuberculosis bakterisinin neden olduğu, genellikle akciğerleri etkileyen bulaşıcı bir hastalıktır. Dünya Sağlık Örgütü (DSÖ) verilerine göre, 2023 yılında dünya genelinde 8.2 milyon kişiye tüberküloz teşhisi konulmuştur [1]. Bu rakam, DSÖ'nün 1995'ten beri yaptığı takiplerde en yüksek seviyeye ulaşmıştır [1]. Tüberküloz, halen dünya genelinde en ölümcül bulaşıcı hastalıklardan biri olmaya devam etmektedir [1].

Geleneksel tüberküloz teşhis yöntemleri, zaman alıcı ve maliyetli olup, özellikle düşük ve orta gelirli ülkelerde erişim zorlukları yaratmaktadır. Bu nedenle, hızlı ve doğru teşhis yöntemlerine duyulan ihtiyaç artmaktadır. Son yıllarda, yapay zekâ (YZ) ve derin öğrenme teknikleri, tıbbi görüntü analizi alanında önemli ilerlemeler kaydetmiştir. Özellikle evrimsel sinir ağları (CNN'ler), görüntü sınıflandırma ve tanıma görevlerinde yüksek performans sergilemektedir. Bu bağlamda, tüberkülozun göğüs röntgenleri üzerinden otomatik olarak sınıflandırılması için transfer öğrenme yaklaşımları, teşhis süreçlerini hızlandırmak ve doğruluğunu artırmak amacıyla kullanılmaktadır [2].

Literatürde, tüberkülozun YZ ve derin öğrenme yöntemleriyle tespiti üzerine çeşitli çalışmalar bulunmaktadır. Örneğin, Yılmaz ve Kaya (2023), tüberküloz hastalığının bilgisayar destekli analiz ve tespitini gerçekleştirmek amacıyla yapay sinir ağları (ANN), evrimsel sinir ağları (CNN) ve hibrit model (VGG19+CNN) kullanmışlardır [2]. Bu çalışmada, 1000 akciğer röntgen görüntüsü hastalıklı ve sağlıklı olarak etiketlenmiş ve önerilen modellerin doğruluk, duyarlılık, kesinlik ve F1-Skor gibi değerlendirme metrikleri kullanılarak performans analizleri yapılmıştır. Sonuçlar, derin öğrenme tabanlı modellerin tüberküloz teşhisinde umut vaat ettiğini göstermektedir [2].

Benzer şekilde, Patel ve arkadaşları (2024), açıklanabilir kendi kendine denetimli derin sinir ağları kullanarak tüberküloz taramasını güçlendirmeyi amaçlamışlardır [4]. Bu çalışmada geliştirilen model, %98,14 genel doğruluk, %95,72 duyarlılık ve %99,44 kesinlik oranlarıyla tüberküloz vakalarını başarılı bir şekilde tespit etmiştir [3]. Bu sonuçlar, modelin klinik olarak anlamlı özellikleri etkili bir şekilde yakaladığını göstermektedir [3].

Rahman ve arkadaşları (2020) ise, göğüs röntgenlerinden tüberkülozun güvenilir bir şekilde tespiti için görüntü ön işleme, veri artırma, görüntü segmentasyonu ve derin öğrenme sınıflandırma tekniklerini kullanmışlardır [4]. Çeşitli derin CNN modelleriyle yapılan deneyler sonucunda, segmentasyon uygulanmış akciğer görüntüleri kullanılarak %99,9 doğruluk, %99,91 kesinlik ve %99,9 duyarlılık elde edilmiştir [5]. Bu çalışma, CNN'lerin segmentasyonlu akciğer bölgelerinden öğrenerek daha yüksek tespit doğruluğuna ulaştığını vurgulamaktadır [4].

Güzel (2022) tarafından yapılan bir doktora tez çalışmasında ise, röntgenler, mikroskopik kan hücreleri ve kalp krizi bulgularından hastalık teşhisi çalışmaları ve derin öğrenme teknikleri birleştirilerek optimize bir model üretilmiştir [5]. Bu bağlamda çalışma boyunca üretilen model, hibrit bir modele dayalı yeni bir derin öğrenme tabanlı mimari sunmaktadır. Mimari temel olarak transfer öğrenme metodolojisinde otomatik kodlayıcı ve SVM sınıflandırıcı kullanılarak önceden eğitilmiş ağlara dayalı olarak tasarlanmıştır [5].

Sonuç olarak, YZ ve derin öğrenme yöntemleri, tüberkülozun hızlı ve doğru teşhisinde önemli bir potansiyele sahiptir. Özellikle transfer öğrenme yaklaşımları, mevcut büyük veri setlerinden öğrenilen bilgilerin yeni ve daha küçük veri setlerine uygulanmasını sağlayarak, teşhis modellerinin etkinliğini artırmaktadır. Bu nedenle, tüberkülozun otomatik sınıflandırılmasında transfer öğrenme yöntemlerinin kullanımı, hem klinik uygulamalarda hem de halk sağlığı stratejilerinde önemli bir rol oynayabilir.

Bu çalışmada, öncelikle modelin eğitim ve test aşamalarında kullanılmak üzere 4 farklı veri kaynağından net ve gürültüsüz olan 512x512 px çözünürlüğe sahip ve etiket bilgileri bilinen 7000 adet göğüs röntgen görüntüsü elde edilmiştir. Bu görüntülerin transfer öğrenme modellerinde kullanılabilmesi için ilk olarak çözünürlük değerleri güncellenip, piksel değerleri 0-255 aralığından 0-1 ondalık aralığına ölçeklendirilerek veri ön işleme adımları uygulanmıştır. Sonrasında TB tespiti için basit CNN ve transfer öğrenme modeli olarak kullanılan VGG16 modelleri özellik çıkarma (feature extraction), ince ayar (fine tuning) ve veri artırma (data augmentation) yöntemleri ayrı ayrı uygulanarak 5 farklı model tasarımı gerçekleştirilmiştir. Bu modeller arasında, veri artırma ve ince ayar teknikleri kullanılarak kısmen tekrardan eğitilen VGG16 modeli ile %99.52 doğruluk, %99 precision, %100 recall ve f1-score oranları ve yaklaşık %100 ROC eğri değerleri elde edilerek en iyi sonucu veren model olmuştur.

## II. METODOLOJİ VE MATERYAL

Önerilen yöntem 3 temel fazdan oluşmaktadır. Bunlar özellik çıkarma, özellik seçme ve sınıflandırma fazlarıdır. Önerilen yöntem xyz veri seti ile eğitilmiş ve test edilmiştir. İlgili fazlar ve xyz veri seti hakkında detaylı bilgi alt bölümlerde sunulmuştur.

Bu çalışmada göğüs röntgen görüntülerinde Tüberküloz tespiti için 5 farklı yöntem kullanılarak derin öğrenme modelleri geliştirilmiştir. Bu yöntemler veri artırma (data augmentation), transfer öğrenme modeli olan VGG-16 ile özellik çıkarma (feature extraction) ve ince ayar (fine-tuning), tam bağlantılı katman ile sınıflandırma yöntemleridir.

Bu yöntemler ile geliştirilen 5 farklı derin öğrenme modellerinin tasarım ve eğitim işlemleri gerçekleştirilmiştir. Test veri setleri üzerinde denenilen modellerin doğruluk-kayıp grafikleri, karmaşıklık matrisleri, model başarı metrikleri ve ROC-AUC eğrileri elde edilmiştir.

Önerilen yöntemler "Tuberculosis (TB) Chest X-ray Cleaned Database" veri seti ile eğitilmiş ve test edilmiştir. İlgili yöntemler ve veri seti hakkında detaylı bilgi alt bölümlerde sunulmuştur.

### A. "Tuberculosis (TB) Chest X-ray Cleaned Database" Veri Seti

Kaggle'da yer alan bu veri seti 4 farklı veri kaynağı tarafından elde edilmiştir. Bunlardan ilki, Amerika Birleşik Devletleri Ulusal Tıp Kütüphanesi tarafından sağlanan ve akciğer hastalıklarının bilgisayar destekli tanısı için kullanılan NLM (National Library of Medicine) veri setidir.

İkincisi, Belarus'ta tüberküloz hastalarına yönelik bir ulusal program kapsamında toplanan ve yüksek çözünürlüklü X-ray ve Bilgisayarlı Tomografi (BT) görüntülerini içeren Belarus TB Portal Programı veri setidir.

Üçüncüsü, ABD Ulusal Alerji ve Bulaşıcı Hastalıklar Enstitüsü tarafından sağlanan, tüberkülozla ilgili çok kapsamlı bir veri deposu olan NIAID TB (National Institute of Allergy and Infectious Diseases Tuberculosis) veri setidir.

Sonuncusu ise, Kuzey Amerika Radyoloji Derneği'nin düzenlediği bir yarışma kapsamında oluşturulan göğüs röntgeni görüntülerine dayalı akciğer hastalıklarının tespiti için geliştirilmiş RSNA CXR (Radiological Society of North America Chest X-ray) veri setidir.

Bu dört veri seti, tüberküloz ve diğer akciğer hastalıklarının teşhisi ve analizi için zengin bir kaynak sunmaktadır. Çalışmada kullanılan veri seti ise bu 4 farklı kaynaktan elde edilen png formatında, 512x512 px çözünürlük değerine sahip, etiketlenmiş 3500 adet normal ve 3500 adet tüberküloz göğüs röntgen görüntülerinden oluşmaktadır. Görüntülere ait etiket bilgisi, görüntülerin dosya isimlerinde yer almaktadır. Örneğin tüberküloz için "Tuberculosis-1400.png", normal yani sağlıklı birey için "Normal-2600.png" şeklinde etiketlenmiştir [6].

Çalışmada, veri setinin %70'i eğitim, %15'i doğrulama ve %15'i test olacak şekilde parçalanmıştır.

## B. Veri Artırma (Data Augmentation)


Veri artırma (Data Augmentation) derin öğrenme modellerinde eğitim verisinin çeşitliliğini artırmak amacıyla kullanılan bir tekniktir. Eğitim veri setindeki her bir görüntü üzerinde rastgele dönüşümler uygulanarak yeni görüntüler oluşturulur. Bu yöntem, modelin genelleme yeteneğini artırır ve aşırı öğrenme (overfitting) riskini azaltır.

Çalışmada doğrulama veri seti için sadece yeniden ölçeklendirme (rescale) işlemi, eğitim veri seti için ise aşağıda verilen veri artırma işlemleri uygulanmıştır.

**Tablo 1.** Eğitim Veri Setine Uygulanan Veri Artırma İşlemleri

İşlem	Değer	Amaç
rescale	1./255	Tüm piksel değerlerini [0,1] aralığına ölçeklendirir.
zoom_range	0.3	Görüntüyü rastgele %30 oranında yakınlaştırır veya uzaklaştırır.
rotation_range	20	Görüntüyü rastgele 20 dereceye kadar döndürür.
width_shift_range	0.2	Görüntüyü yatay ekseninde rastgele %20 oranında kaydırır.
height_shift_range	0.2	Görüntüyü dikey ekseninde rastgele %20 oranında kaydırır.
shear_range	0.2	Görüntüye %20 oranında kayma uygular.
horizontal_flip	True	Görüntüyü yatay olarak rastgele çevirir.
fill_mode	nearest	Boş alanları en yakın pikselin değerleriyle doldurur.

Tablo 1. de verilen parametre ve değerlere göre zenginleştirilen veri setleri ile "tl\_img\_aug\_finetune\_cnn", "tl\_img\_aug\_cnn" ve "img\_aug\_cnn" modellerinin eğitim işlemleri gerçekleştirilmiştir. Şekil 1. de veri artırma işlemi uygulanmış örnek bir görüntü yer almaktadır.



**Şekil 1.** Veri Artırma Uygulanmış Örnek Görsel

## C. Transfer Öğrenme ve VGG-16 Modeli


Transfer öğrenme, önceden büyük veri setlerinde eğitilmiş bir modelin, benzer veya farklı bir görev için yeniden kullanılmasıdır. Derin öğrenme modelleri genellikle büyük miktarda veriye ve hesaplama gücüne ihtiyaç duyar. Transfer öğrenme, bu sınırlamaları aşmak için mevcut modelleri adapte ederek hem eğitim süresini hem de veri gereksinimini önemli ölçüde azaltmaktadır.

### Transfer Öğrenme Süreci:

- Önceden Eğitilmiş Modelin Seçilmesi:** Transfer öğrenme için uygun bir model seçilir. Genelde ImageNet gibi geniş bir veri kümesinde eğitilmiş modeller (VGGNet, ResNet, InceptionNet, EfficientNet) tercih edilir.
- Özellik Çıkarımı (Feature Extraction):** Önceden eğitilmiş modelin evrimsel katmanları, giriş verisinden anlamlı özellikler çıkarmak için kullanılır.
- İnce Ayar (Fine-Tuning):** Modelin belirli katmanları, yeni veri kümesindeki özel özellikleri öğrenmek için yeniden eğitilir.
- Sınıflandırma Katmanı:** Modelin özellik çıkarımı yapan katmanından sonra modelin kendi FC sınıflandırma katmanları çıkartılıp yerine veri setine uygun yeni sınıflandırma katmanları eklenir.
- Modelin Derlenmesi ve Eğitimi:** Model yeni veri seti için, optimizasyon algoritması ve kayıp fonksiyonu gibi metrikler için optimize edilir ve eğitilir.

### VGG-16

VGG-16, 2014 yılında Simonyan ve Zisserman tarafından geliştirilen ve derin evrimsel sinir ağı (CNN) mimarileri arasında önemli bir yere sahip olan bir modeldir [7]. ImageNet veri setinde eğitilen ve 16 katmandan oluşan bu model, özellikle görüntü sınıflandırma ve özellik çıkarımı görevlerinde yaygın olarak kullanılmaktadır [7].



**Şekil 2.** VGG-16 Model Mimarisi

VGG-16, 5 bloktan oluşur ve her blokta belirli sayıda evrimsel katman bulunur. İlk iki blok, giriş görüntüsünden düşük seviyeli özellikleri (örneğin, kenarlar ve dokular) öğrenmek için 64 ve 128 filtre kullanır. Üçüncü, dördüncü ve beşinci bloklar ise daha derin özellikleri öğrenmek için sırasıyla 256 ve 512 filtre içerir. Her evrimsel katmandan sonra, boyut küçültme ve bilgi yoğunluğunu artırma amacıyla 2x2 boyutunda bir max pooling işlemi gerçekleştirilir. Aktivasyon fonksiyonu olarak her evrimsel katmanda ReLU (Rectified Linear Unit) kullanılmıştır, bu da modelin doğrusal olmayan ilişkileri öğrenmesine olanak tanır.

Modelin tam bağlantılı (dense) katmanları, çıkarılan özellikleri sınıflandırma işlemi için kullanılır. Bu katmanlar, 4096 nöron içeren iki ara katman ve bir çıkış katmanından oluşur. Çıkış katmanı, ImageNet veri setindeki 1000 sınıfı temsil etmek üzere softmax aktivasyon fonksiyonu ile yapılandırılmıştır. Bununla birlikte, transfer öğrenme uygulamalarında bu tam bağlantılı katmanlar genellikle çıkarılarak yerine yeni görev için özelleştirilmiş sınıflandırıcı katmanlar eklenir.

#### D. VGG-16 ile Özellik Çıkarımı

VGG-16'nın transfer öğrenme kapsamında özellik çıkarımı için kullanımı, modelin önceden öğrenilmiş ağırlıklarının yeni bir veri kümesindeki özellikleri çıkarmak amacıyla uygulanmasını içerir. Bu süreçte, VGG-16'nın tam bağlı (fully connected) katmanları çıkarılır ve modelin evrimsel katmanları, yeni veri kümesindeki görüntülerden anlamlı özellikler elde etmek için kullanılır. Elde edilen bu derin özellikler, daha sonra destek vektör makineleri (SVM), k-en yakın komşu (k-NN) veya rastgele ormanlar (Random Forest) gibi geleneksel makine öğrenimi algoritmalarıyla sınıflandırılabilir [8].

Örneğin, Tammina (2019) tarafından yapılan bir çalışmada, VGG-16 modeli transfer öğrenme ile kullanılarak görüntü sınıflandırma gerçekleştirilmiştir. Bu çalışmada, VGG-16'nın evrimsel katmanları kullanılarak özellikler çıkarılmış ve bu özellikler, yeni sınıflandırma görevleri için kullanılmıştır [8]. Sonuçlar, transfer öğrenmenin sınırlı veri setleri üzerinde bile yüksek doğruluk sağladığını göstermektedir [8].

VGG-16'nın transfer öğrenme ile özellik çıkarımı, tıbbi görüntü analizi gibi alanlarda da başarılı bir şekilde uygulanmıştır. Örneğin, Ohata ve arkadaşları (2021), COVID-19 teşhisi için X-ışını görüntülerinden özellikler çıkarmak amacıyla VGG-16 modelini kullanmış ve bu özellikleri çeşitli makine öğrenimi sınıflandırıcılarıyla değerlendirmiştir. Bu çalışma, transfer öğrenme tabanlı özellik çıkarımının tıbbi teşhis süreçlerinde etkin bir araç olduğunu göstermektedir [9].

Bu çalışmada VGG-16 modeli eğitim ve doğrulama veri setlerine uygulanarak bu verilerden anlamlı darboğaz özellikleri (bottleneck feature) elde edilmiştir. Bottleneck features, bir derin öğrenme modelinin genellikle tam bağlantılı (fully connected) katmanlarına geçmeden önceki son evrimsel (convolutional) veya havuzlama (pooling) katmanında elde edilen öznel özelliklerdir. Bu öznel özellikler, giriş verisinin model tarafından özetlenmiş ve filtrelenmiş hali olarak düşünülebilir.

Darboğaz özellikleri VGG-16 modelinin block-5 çıkışından sonra flatten katmanı kullanılarak 1 x 8192 boyut değeri ile elde edilmiştir. Bu özellikleri TB sınıflandırma problemine entegre etmek için flatten katmanından sonra sınıflandırma katmanları eklenerek "tl\_cnn" isimli modelin eğitimi gerçekleştirilmiştir. Bir diğer "tl\_img\_aug\_cnn" isimli modelde ise aşırı uyum (over fitting) sorununun önüne geçebilmek için öncelikle eğitim veri setlerine veri artırma işlemi uygulanmış ve sonrasında VGG-16 modeli kullanılarak özellik çıkarım işlemi gerçekleştirildikten sonra sınıflandırma katmanlarının eğitimi gerçekleştirilmiştir.


#### E. VGG-16 ile İnce Ayar (Fine Tuning)

Transfer öğrenme, geniş veri setleri üzerinde eğitilmiş derin öğrenme modellerinin, benzer veya farklı görevler için yeniden uyarlanmasını ifade eder. Bu yaklaşım, sınırlı veri setleri ve hesaplama kaynaklarına sahip durumlarda etkili bir çözüm sunar. VGG-16, transfer öğrenme uygulamalarında sıkça kullanılan derin bir evrimsel sinir ağı modelidir. Model, derinliği ve düzenli mimarisi sayesinde hem düşük seviyeli hem de yüksek seviyeli özellikleri öğrenmekte başarılıdır [8]. İnce ayar (fine-tuning), transfer öğrenmenin ileri bir uygulaması olup, modelin belirli katmanlarının yeniden eğitilmesi veya tamamen özelleştirilmesi yoluyla performansın artırılmasını hedefler [10].

VGG-16, toplamda 16 ağırlık katmanından (13 evrimsel ve 3 tam bağlantılı katman) oluşur. İnce ayar sürecinde genellikle modelin son tam bağlantılı katmanları çıkarılır ve yeni görev için uygun bir sınıflandırıcı eklenir. Örneğin, tıbbi görüntü analizi gibi alanlarda, son katman bir sigmoid aktivasyon fonksiyonu ile değiştirilerek ikili sınıflandırma yapılabilir [8]. İnce ayar işlemi sırasında, modelin alt katmanlarındaki ağırlıklar genellikle sabitlenir (eğitilmez), çünkü bu katmanlar düşük seviyeli genel özellikleri öğrenir ve farklı görevlerde genelleştirilebilir [10]. Üst katmanlar ise yeni veri setine uyum sağlayacak şekilde yeniden eğitilir ve bu süreç, modelin hedef göreve daha iyi uyum sağlamasını sağlar [8].

Örneğin, Tammina (2019) tarafından yapılan bir çalışmada, VGG-16 modeli, farklı görüntü sınıflandırma görevleri için transfer öğrenme ve ince ayar yöntemleriyle adapte edilmiş ve yüksek doğruluk oranları elde edilmiştir [8]. Benzer şekilde, Su ve Wang (2022), VGG-16 modelini ruhan arıza teşhisi için ince ayar yaparak, modelin performansını artırmışlardır [10]. Bu çalışmalar, ince ayarın transfer öğrenme sürecinde performansı artırma önemli bir yöntem olduğunu göstermektedir. Özellikle sınırlı veri setlerinde, ince ayar yöntemi modelin genelleme kapasitesini korurken hedef görevde daha yüksek doğruluk sağlar [8][10].

Transfer öğrenme modelleri üzerinde ince ayar işleminde, özellik çıkarımı yapan evrimsel katman içeren blokların eğitime kapatılması (freeze) veya eğitime açılması işlemleri gerçekleştirilir. Bu noktada hangi blokların dondurulacağına veya eğitime açılacağına karar verilirken modelin eğitiminde kullanılacak veri setinin boyutu ve bu veri setinin transfer öğrenme modelinin ilk eğitiminde kullanılan veri setine benzerliğine bakılarak karar verilmektedir. Bu iki parametreye göre eğitime açılacak katmanların belirlenme işlemi Şekil 3. de gösterilmektedir.



Şekil 3. Transfer Öğrenme ile İnce Ayar'da Eğitime Açılacak Blokların Belirlenmesi

Bu çalışmada kullanılan VGG-16 transfer öğrenme modelinin ilk eğitiminde kullanılan veri seti ile çalışmada kullanılan veri seti birbirine benzemediği için ve veri seti sayısı az olduğu için VGG-16 modelinin blok-4 ve blok-5 katmanları ile birlikte sınıflandırma katmanları eğitime açılıp, geri kalan katmanlar dondurularak "tl\_img\_aug\_finetune\_cnn" isimli model geliştirilmiştir.

#### F. Derin Öğrenme Tabanlı Sınıflandırma Yöntemi

Derin evrimsel sinir ağları (CNN'ler), görüntü sınıflandırma görevlerinde yaygın olarak kullanılmakta olup, bu ağların üzerine eklenen sınıflandırıcı katmanlar modelin genel performansını belirlemede kritik bir rol oynamaktadır. Güncel literatürde, CNN'lerin üzerine eklenen sınıflandırıcılar için üç temel yaklaşım öne çıkmaktadır: tam bağlantılı katmanlar (fully-connected layers), global ortalama havuzlama (global average pooling) ve doğrusal destek vektör makineleri (linear support vector machines) [11][12].

##### Tam Bağlantılı Katmanlar (Fully-Connected (FC) Layers)

Geleneksel CNN mimarilerinde, evrimsel katmanların ardından bir veya daha fazla tam bağlantılı katman eklenerek, çıkarılan özelliklerin sınıflandırılması sağlanır. Bu yaklaşım, modelin karmaşık ilişkileri öğrenmesine olanak tanır; ancak, parametre sayısının artması nedeniyle aşırı öğrenme (overfitting) riski ve hesaplama maliyetleri de yükselir. Zafar ve arkadaşları (2024), farklı havuzlama yöntemlerini karşılaştırdıkları çalışmalarında, tam bağlantılı katmanların kullanımının modelin performansını artırdığını, ancak hesaplama maliyetlerini de yükselttiğini belirtmişlerdir [13].

### Global Ortalama Havuzlama (Global Average Pooling)

Lin ve arkadaşları (2013) tarafından önerilen bu yöntem, tam bağlantılı katmanlar yerine, her bir özellik haritasının ortalamasını alarak doğrudan sınıflandırma katmanına iletmeyi amaçlar. Bu yaklaşım, modelin aşırı öğrenme riskini azaltırken, uzamsal bilginin korunmasını da sağlar. Ayrıca, modelin parametre sayısını düşürerek hesaplama verimliliğini artırır [14].

### Doğrusal Destek Vektör Makineleri (Linear Support Vector Machines)

Evrişimsel katmanlar tarafından çıkarılan özelliklerin, doğrusal bir SVM ile sınıflandırılması, özellikle sınırlı veri setlerinde modelin genelleme yeteneğini artırabilir. Gao ve arkadaşları (2016), kompakt bilinear havuzlama yöntemini kullanarak, SVM tabanlı sınıflandırıcıların performansını artırmayı başarmışlardır [15].

Sonuç olarak, derin evrişimsel sinir ağlarının üzerine eklenen sınıflandırıcı katmanların seçimi, modelin genel performansı üzerinde belirleyici bir etkiye sahiptir. Tam bağlantılı katmanlar, karmaşık ilişkileri öğrenmede etkili olsa da, hesaplama maliyetleri ve aşırı öğrenme riski taşır. Global ortalama havuzlama, parametre sayısını azaltarak modelin genelleme yeteneğini artırırken, doğrusal SVM'ler özellikle sınırlı veri setlerinde etkili bir sınıflandırma yöntemi sunar.

Çalışmada sınıflandırma katmanı olarak tam bağlantılı katmanlar kullanılmış ve son tam bağlantılı katmanda Sigmoid aktivasyon fonksiyonu kullanılarak 2 sınıf değeri için üretilen tahmin değerleri Normal (0) veya TB (1) etiket değerleri elde edilmiştir.

### G. Model Tasarımları


Bu çalışmada, derin öğrenme tabanlı 3 farklı resim sınıflandırma modeli tasarımı ve nihayetinde 5 adet model geliştirilmiştir. Kullanılan modeller, Keras derin öğrenme kütüphanesinin Sequential API'si ile oluşturulmuş ve Evrişimsel Sinir Ağları (Convolutional Neural Network, CNN) mimarisi üzerine yapılandırılmıştır. CNN modelleri, görüntü işleme ve sınıflandırma alanında yaygın olarak kullanılmakta olup, öğrenme sürecinde görüntülerden anlamlı özellikleri çıkarabilme yetenekleri sayesinde başarılı sonuçlar elde etmektedir.

Oluşturulan modeller, sırasıyla evrişimsel katmanlar (Conv2D), alt örnekleme katmanları (MaxPooling2D), düzleştirme katmanı (Flatten) ve tam bağlantılı katmanlardan (Dense) oluşmaktadır. Her evrişim katmanından sonra, aktivasyon fonksiyonu olarak ReLU (Rectified Linear Unit) ve son tam bağlantılı katmanda sınıflandırma işlemi için Sigmoid kullanılmıştır.

- **Evrişimsel katmanlar (Conv2D):** modellerin görüntülerden düşük ve yüksek seviyeli özellikleri öğrenmesini sağlar.
- **Alt Örnekleme Katmanları (MaxPooling2D):** Her evrişim katmanından sonra uygulanıp, belirli bir havuzlama alanındaki maksimum değeri seçerek, görüntüdeki en belirgin özelliklerin korunmasını sağlar.
- **Düzleştirme Katmanı (Flatten):** Evrişim ve alt örnekleme katmanından sonra elde edilen özellik haritaları, sınıflandırma işlemi için düz bir vektör haline getirilir. Bu işlem, çok boyutlu bir matrisin tek boyutlu bir diziye dönüştürülmesini sağlar.
- **Tam Bağlantılı Katmanlar (Dense / FC):** Düzleştirme katmanı ile son sınıflandırma katmanı arasında kalan FC katmanları, düzleştirilmiş özellik vektörlerini işleyerek daha soyut temsiller öğrenir. Son FC katmanı ise sınıflandırma işlemini gerçekleştiren tek bir nörondan oluşur. Aktivasyon fonksiyonu olarak sigmoid kullanılmıştır. Sigmoid fonksiyonu, 0 ile 1 arasında bir değer üretir ve bu, ikili sınıflandırma problemlerinde bir tahmin olasılığı olarak yorumlanır.


Transfer öğrenme yönteminin başarısını test etmek ve kıyaslamak için ilk geliştirilen "basic\_cnn" isimli Model-1 tasarımı Şekil 4. te verilmiştir. Bu model tasarımında özellik çıkarımı için 3 adet evrişimsel ağ ile birlikte beraberinde havuzlama katmanı kullanılmış ve

sınıflandırma katmanında düzleştirme katmanı ile özellikler 1 boyutlu diziye dönüştürülüp tam bağlantılı katmanlar ve sigmoid aktivasyon fonksiyonu kullanılmıştır.



Şekil 4. Model-1 basic\_cnn Model Mimarisi

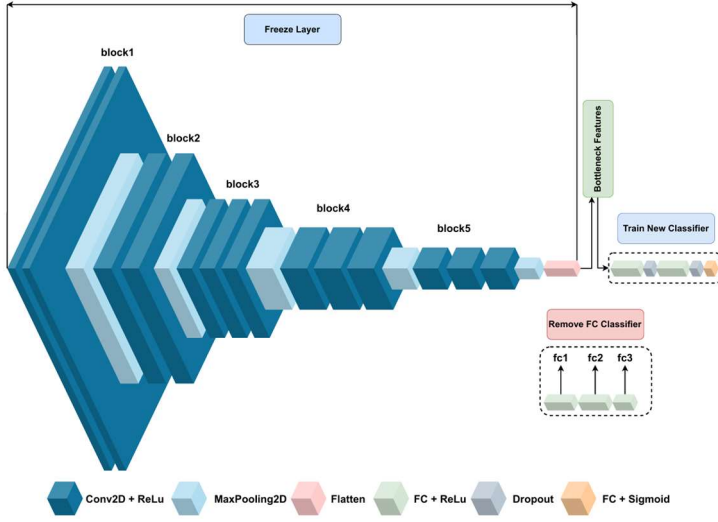
Aşırı öğrenme'den (over-fitting) kaçınmak ve modelin genelleme performansını artırmak için "img\_aug\_cnn" isimli Model-2 tasarımında evrişimsel katman sayısı artırılıp sınıflandırma katmanında yer alan tam bağlantılı katmanlardan sonra dropout katmanları eklenmiş ve bu modelin eğitiminde kullanılan veri setine veri artırma (data augmentation) yöntemi uygulanmıştır. Bu modelin mimarisi Şekil 5. te verilmiştir.



Şekil 5. Model-2 img\_aug\_cnn Model Mimarisi


Transfer öğrenme modeli olarak kullanılan VGG-16 ile özellik çıkarma (feature extraction) tekniği kullanılarak "tl\_cnn" ve "tl\_img\_aug\_cnn" isimli Model-3 ve Model-4 modelleri geliştirilmiştir. Özellik çıkarım aşamasında VGG-16 modelinin özellik çıkarımı işlemini gerçekleştiren bütün evrişimsel bloklar (blok 1-5) eğitime kapatılıp (freeze), düzleştirme katmanı üzerinden anlamlı darboğaz özellikleri (bottleneck features) 1 x 8192 boyutunda elde edilip sonrasında eklenen sınıflandırma katmanı ile model tasarımı gerçekleştirilmiştir. Model-3'ün karşılaşılabileceği aşırı uyum sorunundan kaçınmak için Model-4'ün eğitiminde kullanılan veri setlerine veri artırma yöntemi uygulanmıştır. İlgili modellerin mimarileri Şekil 6. da verilmiştir.





Şekil 6. Model-3/4 tl\_cnn ve tl\_img\_aug\_cnn Model Mimarisi

Son olarak transfer öğrenme modeli olarak kullanılan VGG-16'nın blok-4 ve blok-5 katmanları eğitime açılıp geri kalan evrimsel katmanları eğitime kapatarak (freeze) ince ayar (fine-tuning) yöntemi uygulanmış ve son olarak veri seti veri artırma yöntemi ile zenginleştirilip geliştirilen "tl\_img\_aug\_finetune\_cnn" isimli Model-5'in genelleme yeteneğinin artırılması hedeflenmiştir. Bu modelin mimarisi ise Şekil 7. de verilmiştir.



Şekil 7. Model-5 tl\_img\_aug\_finetune\_cnn Model Mimarisi

### III. DENEYSEL ÇALIŞMALAR


#### A. Deneyisel Kurulum

Bu çalışma Google Colab üzerinde NVIDIA Tesla T4 GPU donanımı, python programlama dili ve TensorFlow Keras kütüphanesi kullanılarak gerçekleştirilmiştir. Veri seti ilk olarak Google Drive'a aktarılıp sonrasında Google Colab ile entegrasyonu sağlanmıştır.


#### B. Deneyisel Sonuçlar

Derin öğrenme modelleri eğitildikten sonra, her bir sınıfa ait 525, toplamda 1050 test veri seti ile modellerin performansları test edildi. Performans metriği olarak, doğruluk, Kesinlik, duyarlılık, F1-skor ve ROC eğrisi metrikleri kullanıldı.


Geliştirilen 5 modele ait eğitim-doğrulama veri setleri üzerinde elde edilen doğruluk-kayıp değerleri gösteren grafikler aşağıda verilmiştir.




Şekil 8. Model-1 basic\_cnn Doğruluk-Kayıp Grafiği




Şekil 9. Model-2 img\_aug\_cnn Doğruluk-Kayıp Grafiği



Şekil 10. Model-3 tl\_cnn Doğruluk-Kayıp Grafiği



Şekil 11. Model-4 tl\_img\_aug\_cnn Doğruluk-Kayıp Grafiği



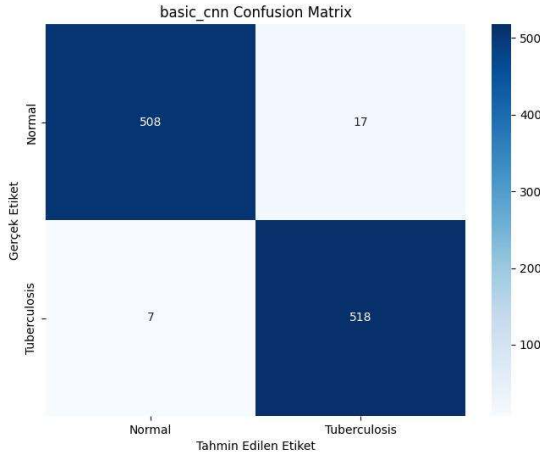
Şekil 12. Model-5 tl\_img\_aug\_finetune\_cnn Doğruluk-Kayıp Grafiği

## Karmaşıklık Matrisi (Confusion Matrix)

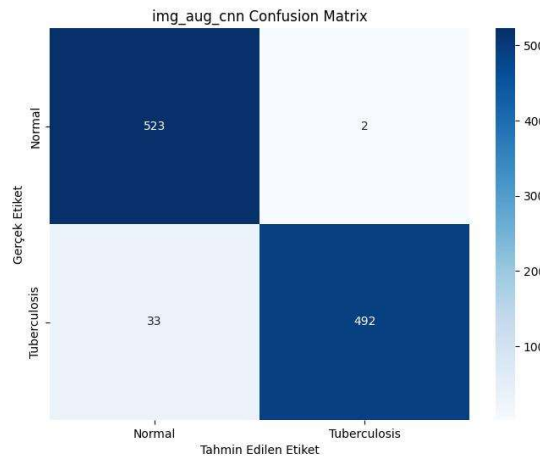
Karmaşıklık matrisi (confusion matrix), sınıflandırma modellerinin performansını değerlendirmek için kullanılan bir tablodur. Gerçek sınıflar ile modelin tahmin ettiği sınıflar arasındaki ilişkiyi sayısal olarak gösterir. Bu matris, özellikle ikili ve çok sınıflı sınıflandırma problemlerinde modelin doğruluğunu, hatalarını ve sınıflar arası karışıklıkları analiz etmek için temel bir araçtır. Bu matris sonucu elde edilen TP, TN, FP ve FN değerleri kullanarak sınıflandırma problemi için model performans metrikleri hesaplanabilir.

- **True Positive (TP):** Gerçek sınıf pozitif ve model doğru bir şekilde pozitif olarak tahmin etmiştir.
- **True Negative (TN):** Gerçek sınıf negatif ve model doğru bir şekilde negatif olarak tahmin etmiştir.
- **False Positive (FP):** Gerçek sınıf negatif olmasına rağmen model yanlışlıkla pozitif olarak tahmin etmiştir (Tip I hata).
- **False Negative (FN):** Gerçek sınıf pozitif olmasına rağmen model yanlışlıkla negatif olarak tahmin etmiştir (Tip II hata).

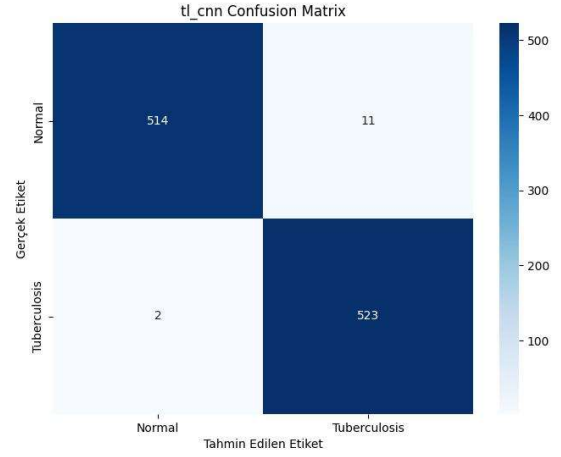
Bu çalışmada test veri setleri üzerinde modellerden elde edilen karmaşıklık matrisleri aşağıda verilmiştir.



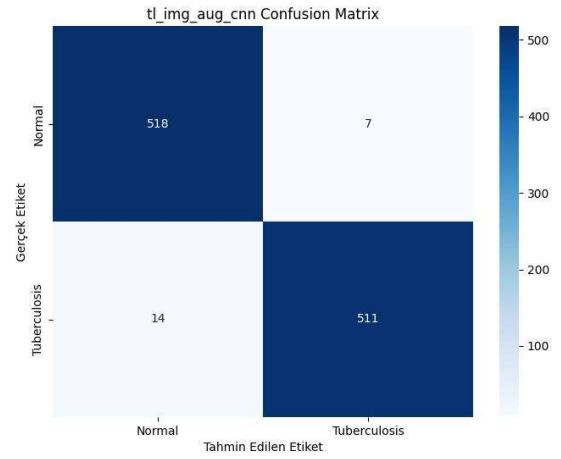
Şekil 13. Model-1 basic\_cnn Karmaşıklık Matrisi



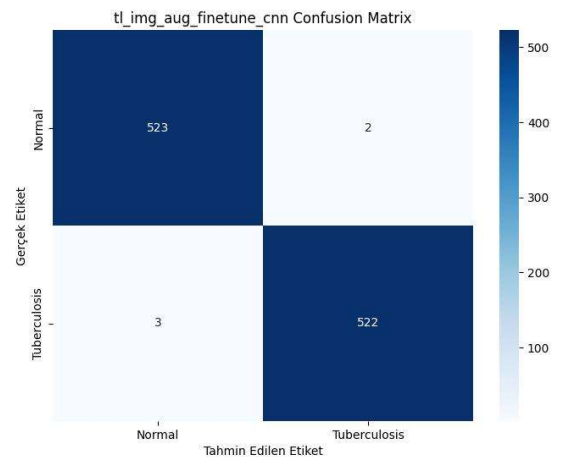
Şekil 14. Model-2 img\_aug\_cnn Karmaşıklık Matrisi



Şekil 15. Model-3 tl\_cnn Karmaşıklık Matrisi



Şekil 16. Model-4 tl\_img\_aug\_cnn Karmaşıklık Matrisi



Şekil 17. Model-5 tl\_img\_aug\_finetune\_cnn Karmaşıklık Matrisi

Test veir setleri üzerinde modellerden elde edilen karmaşıklık matris değerleri Tablo 2. de verilmiştir.

**Tablo 2.** Modellerin Karmaşıklık Matris Değerleri.

Model / CM	TP	TN	FP	FN
basic_cnn	518	508	17	7
img_aug_cnn	492	523	2	33
tl_cnn	523	514	11	2
tl_img_aug_cnn	511	518	7	14
<b>tl_img_aug_finetune_cnn</b>	<b>522</b>	<b>523</b>	<b>2</b>	<b>3</b>

Karmaşıklık matrisi, modelin sınıflandırma performansını değerlendirmek için çeşitli metriklerin hesaplanmasını sağlar. Bu metrikler, modelin güçlü ve zayıf yönlerini anlamamıza, hataları analiz etmemize ve uygulama senaryolarına göre en uygun modeli seçmemize yardımcı olur.

#### Doğruluk (Accuracy)

Modelin tüm tahminlerinin ne kadarının doğru olduğunu ifade eder. En yaygın kullanılan performans metriğidir. Eşitlik 1 kullanılarak hesaplanır.

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \quad (1)$$

#### Kesinlik (Precision)

Modelin pozitif olarak tahmin ettiği örneklerin ne kadarının gerçekten pozitif olduğunu ifade eder. Yanlış pozitifleri azaltmaya odaklanır. Eşitlik 2 kullanılarak hesaplanır.

$$Precision = \frac{TP}{TP + FP} \quad (2)$$

#### Duyarlılık (Recall)

Gerçek pozitif sınıfın ne kadarının doğru bir şekilde tahmin edildiğini gösterir. Yanlış negatifleri azaltmaya odaklanır. Eşitlik 3 kullanılarak hesaplanır.

$$Recall = \frac{TP}{TP + FN} \quad (3)$$

#### F1-Skoru (F1-Score)

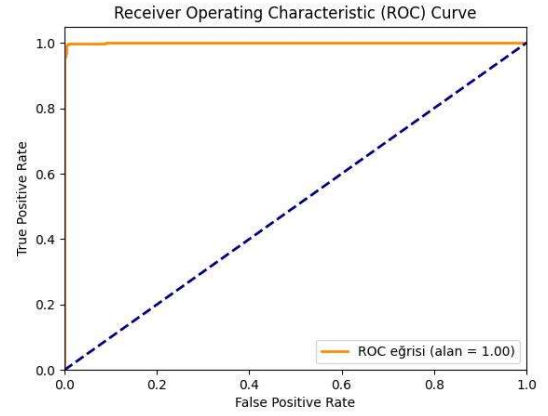
Kesinlik ve duyarlılık arasında bir denge sağlar. Her ikisinin harmonik ortalaması olarak hesaplanır. Eşitlik 4 kullanılarak hesaplanır.

$$F1\ Score = 2 \times \frac{Precision \times Recall}{Precision + Recall} \quad (4)$$

#### ROC Eğrisi ve AUC

ROC Eğrisi (Receiver Operating Characteristic Curve), modelin duyarlılık (recall) ile yanlış pozitif oranını (False Positive Rate) farklı eşik değerlerinde nasıl değiştirdiğini gösterir.

AUC (Area Under Curve), ROC eğrisinin altındaki alan. AUC, modelin sınıflandırma yeteneğini değerlendirir; 1.0 mükemmel bir model, 0.5 ise rastgele tahmin anlamına gelir. AUC, modelin genel performansı hakkında tek bir sayı sağlar. 0.9 üzerindeki AUC değerleri oldukça başarılıdır.



**Şekil 18.** Model-5 tl\_img\_aug\_finetune\_cnn ROC Eğri Grafiği

Çalışmada geliştirilen modellerin performans metrikleri, Tablo 2. de elde edilen karmaşıklık matrisi değerleri ve metrik hesaplama eşitlikleri kullanılarak hesaplanmış ve Tablo 3. te verilmiştir. Elde edilen sonuçlara göre “tl\_img\_aug\_finetune\_cnn” isimli transfer öğrenme ince ayar ve veri zenginleştirme ile eğitilen Model-5 ile en iyi sonuçları vermektedir.

**Tablo 3.** Modellerin Performans Metrikleri.

Model / MM	Accuracy	Precision	Recall	F1
basic_cnn	97,71	96,82	98,67	97,74
img_aug_cnn	96,67	99,60	93,71	96,57
tl_cnn	98,76	97,94	99,62	98,77
tl_img_aug_cnn	98,00	98,65	97,33	97,99
<b>tl_img_aug_finetune_cnn</b>	<b>99,52</b>	<b>99,62</b>	<b>99,43</b>	<b>99,52</b>

## IV. DEĞERLENDİRME

Yapılan çalışmada 5 farklı modelin eğitimi gerçekleştirilmiş ve aralarında en iyi başarı metrik değerini transfer öğrenme modeli olan VGG-16 ile ince ayar yapılan ve veri artırma tekniği uygulanan model ile elde edilmiştir. Veri artırma yöntemi ve dropout kullanılan modellerde aşırı uyumun önüne geçildiği ve modelin genelleme performansının arttığı gözlemlenmiştir. Ayrıyeten transfer öğrenme modellerinde ince ayar işlemini veri setinin benzerliği ve boyutu gibi parametreleri dikkate alarak gerçekleştirilmesi daha başarılı model sonuçlarının elde edilmesini sağlamaktadır. Modellerin sınıflandırma katmanında yer alan tam bağlantılı katmanlar ile başarılı bir sınıflandırma modeli gerçekleştirilmiştir. Deney sonuçlarında en iyi başarıyı veren model ile literatürde yapılan diğer çalışmalar Tablo 4. de kıyaslanmış ve daha başarılı bir doğruluk ve AUC değeri elde edilmiştir.

**Tablo 4.** Önerilen yaklaşımın literatür teknikleriyle karşılaştırılması.

Çalışma	Metot	Veri Seti	Veri Adedi (TB+N)	Accuracy	AUC
[16]	DenseNet	MIMIC+CheXpert	1500 (780+720)	66.5	0.81
[17]	Topo-CXR	Shenzhen CXR	662 (326+336)	89.5	0.94
[18]	VGG16	Montgomery+Shenzhen	800 (394+406)	81.25	NA
[19]	ResNet50	Shenzhen+Montgomery County	3040	76.8	NA
[20]	ResNet-BS	Montgomery+Shenzhen	800 (394+406)	92.3	0.96
[21]	DenseNet	Montgomery, Shenzhen and Bureau TB	NA	91	0.95
[22]	TB-UNet	Local CXR Data	2903+7994	85	NA
[23]	Self-Trained CNN	Tuberculosis (TB) Chest X-ray Cleaned Database	7000 (3500+3500)	96.57	0.99
<b>Mevcut</b>	<b>VGG16</b>	<b>Tuberculosis (TB) Chest X-ray Cleaned Database</b>	<b>7000 (3500+3500)</b>	<b>99.52</b>	<b>1</b>

## V. KAYNAKLAR

- [1] World Health Organization. (2023). Global Tuberculosis Report 2023. Erişim: <https://www.who.int/publications/i/item/9789240061729>.
- [2] Yılmaz, M., & Kaya, A. (2023). Tüberküloz Hastalığının Tespiti için Derin Öğrenme Yöntemlerinin Kullanımı. *Osmaniye Korkut Ata Üniversitesi Fen Bilimleri Enstitüsü Dergisi*, 6(2), 123-135.
- [3] Patel, N., Wong, A., & Ebadi, H. (2024). Explainable Self-Supervised Learning for Tuberculosis Screening. *International Journal of Medical Informatics*.
- [4] Rahman, T., Khandakar, A., & Mahmud, S. (2020). Automated Tuberculosis Detection using Chest X-ray Images with Deep Learning: An Extensive Evaluation. *IEEE Access*, 8, 191102-191112.
- [5] Güzel, C. (2022). Akciğer Röntgen Görüntülerinden Hastalık Tespiti için Derin Öğrenme Yöntemlerinin Kullanımı. Doktora Tezi, Anadolu Üniversitesi Fen Bilimleri Enstitüsü.
- [6] Kaggle. (2024). Tuberculosis (TB) Chest X-ray Cleaned Database. Erişim: <https://www.kaggle.com/datasets/scipygaurav/tuberculosis-tb-chest-x-ray-cleaned-database>.
- [7] Simonyan, K., & Zisserman, A. (2014). Very Deep Convolutional Networks for Large-Scale Image Recognition. *arXiv preprint arXiv:1409.1556*.
- [8] Tammina, S. (2019). Transfer learning using VGG-16 with Deep Convolutional Neural Network for Classifying Images. *International Journal of Scientific and Research Publications*, 9(10), 143-150.
- [9] Ohata, E. F., Bezerra, G. M., & da Costa, C. A. (2021). Deep Learning for COVID-19 Diagnosis in Chest X-Ray Images: Feature Extraction using VGG-16. *Springer Advances in Intelligent Systems and Computing*.
- [10] Su, J., & Wang, H. (2022). Fine-tuning and efficient VGG16 transfer learning fault diagnosis method for rolling bearing. In *Proceedings of IncoME-VI and TEPEN 2021* (pp. 453-461). Springer, Singapore.
- [11] Krizhevsky, A., Sutskever, I., & Hinton, G. E. (2012). Imagenet classification with deep convolutional neural networks. *Advances in Neural Information Processing Systems*, 25, 1097-1105.
- [12] Simonyan, K., & Zisserman, A. (2014). Very deep convolutional networks for large-scale image recognition. *arXiv preprint arXiv:1409.1556*.
- [13] Zafar, M., Jabeen, F., & Khan, S. (2024). Pooling techniques comparison in deep learning models: Fully-connected layers and alternatives. *Symmetry*, 16(11), 1516.
- [14] Lin, M., Chen, Q., & Yan, S. (2013). Network in network. *arXiv preprint arXiv:1312.4400*.
- [15] Gao, Y., Beijbom, O., Zhang, N., & Darrell, T. (2016). Compact bilinear pooling. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)* (pp. 317-326).
- [16] Liu, C. J., Tsai, C. C., Kuo, L. C., et al. (2023). A deep learning model using chest X-ray for identifying TB and NTM-LD patients: A cross-sectional study. *Insights Into Imaging*, 14, 67.
- [17] Ahmed, F., Nuwagira, B., Torlak, F., & Coskunuzer, B. (2023). Topo-CXR: Chest X-ray TB and Pneumonia Screening with Topological Machine Learning. *2023 IEEE/CVF International Conference on Computer Vision Workshops (ICCVW)*, Paris, France, 2318-2328.
- [18] Ahsan, M., Gomes, R., & Denton, A. (2019). Application of a convolutional neural network using transfer learning for tuberculosis detection. *2019 IEEE International Conference on Electro Information Technology (EIT)*, Brookings, SD, USA, 427-433.
- [19] Devasia, J., Goswami, H., Lakshminarayanan, S., et al. (2022). Deep learning classification of active tuberculosis using chest X-rays: Efficacy of transfer learning and generalization performance of cross-population datasets. *Preprint (Version 1)*.
- [20] Rajaraman, S., Zamzmi, G., Folio, L., Alderson, P., & Antani, S. (2021). Chest X-ray bone suppression for improving classification of tuberculosis-consistent findings. *Diagnostics*, 11(5), 840.
- [21] Pattanasuwan, C., & Chongstitvatana, P. (2021). Screening TB using deep transfer learning. *2021 25th International Computer Science and Engineering Conference (ICSEC)*, Chiang Rai, Thailand, 330-333.
- [22] Nijati, M., Zhang, Z., Abulizi, A., et al. (2021). Deep learning assistance for tuberculosis diagnosis with chest radiography in low-resource settings. *Journal of X-Ray Science and Technology*, 29(5), 785-796.
- [23] Sarawagi, K., Pagrotra, A., Dhiman, H., & Singh, N. (2024). Self-trained convolutional neural network (CNN) for tuberculosis diagnosis in medical imaging. *Cureus*, 16(6), e63356.

## VI. EKLER

### Github Kaynak Kod:

[https://github.com/Rexoes/Artificial-Intelligence-and-Deep-Learning-in-Health-PhD-Lecture/blob/main/AUE\\_Tuberculosis\\_TransferLearning\\_OriginalData.ipynb](https://github.com/Rexoes/Artificial-Intelligence-and-Deep-Learning-in-Health-PhD-Lecture/blob/main/AUE_Tuberculosis_TransferLearning_OriginalData.ipynb)